(一) 結果分析

1. 學習表現

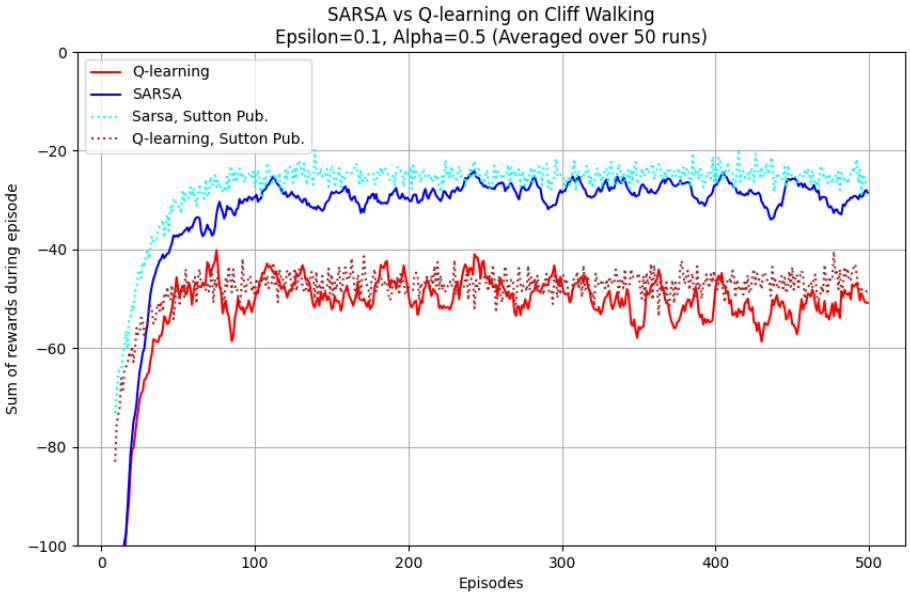

• 現象解釋（累積獎勵曲線）：如上圖所示，在訓練過程中，SARSA 的累積獎勵快速上升並趨於穩定，整體維持在較高且平穩的水準；而 Q-learning 的累積獎勵則一直在較低的水準劇烈波動。此現象說明 SARSA 很快地學習到了安全的避險路徑，而 Q-learning 在尋找最短路徑的過程中，由於經常在懸崖邊緣探索，導致頻繁掉入懸崖而獲得極低的獎勵與巨大波動。

• 收斂速度比較：在相同回合數下，Q-learning 與 SARSA 均能收斂。以策略學習觀之，Q-learning 直接更新全局最優動作價值，通常能較快學習到理論最佳路徑。然就累積獎勵收斂速度而言，SARSA 因採取避險策略，其累積獎勵曲線在初期會更快趨於穩定，且整體獎勵較高。

2. 策略行為

Q-learning 最終學習路徑：

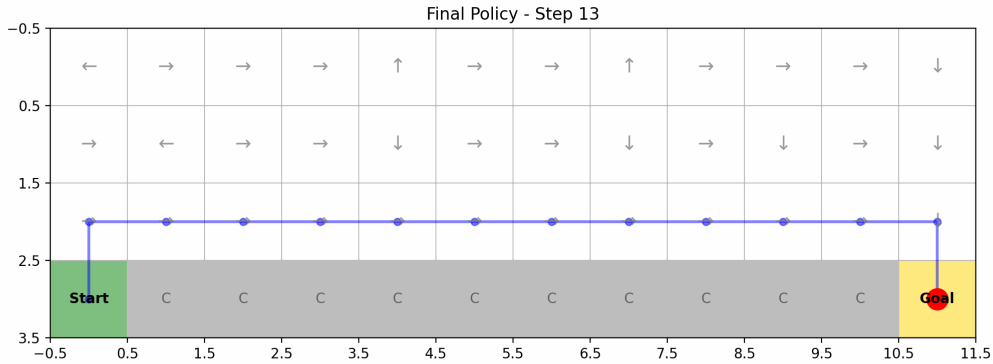

SARSA 最終學習路徑：

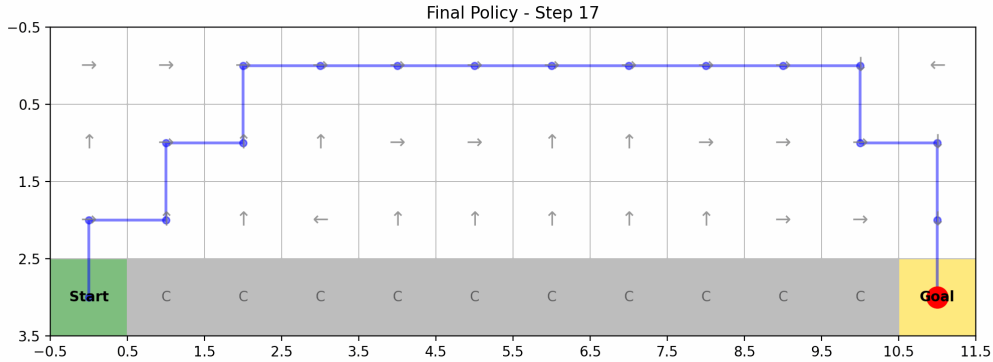

• 現象解釋（路徑視覺化）：如上圖所示，Q-learning（上圖）選擇了緊貼懸崖邊緣的最短危險路徑；SARSA（下圖）則選擇了遠離懸崖的安全路徑。這印證了 Q-learning 傾向冒險，為追求最少步數的高報酬而走在懸崖邊緣；SARSA 則傾向保守，在更新價值時考量了探索策略導致掉入懸崖的風險，進而選擇遠離危險區域。

• 最終學習路徑與傾向分析：視覺化結果明確顯示 Q-learning 學習到的是理論上的最優解（最短路徑），但風險極高；SARSA 學習到的是次優解（較長路徑），但在存在隨機探索的環境中更為安全。

3. 穩定性分析

• 學習過程波動程度：結合累積獎勵曲線可見，Q-learning 學習過程中的獎勵波動劇烈，因其最優路徑鄰近懸崖，在保持探索率的情況下極易掉入懸崖；SARSA 的波動程度較小，其路徑安全，即便隨機探索亦不易導致嚴重懲罰。

• 探索對結果的影響：探索機制使得 Q-learning 在訓練期間表現較差，頻繁偏離最優路徑；SARSA 則將探索帶來的潛在風險納入價值評估，其策略能容忍探索行為，展現較高穩定性。

(二) 理論比較與討論

• Q-learning 為離策略（Off-policy）方法，其更新目標為下一狀態的全局最大 Q 值，不考慮當前實際執行的探索策略。因此，它能學習到全局最佳策略（最短路徑），但在訓練過程中因未評估探索風險，容易掉入懸崖。

• SARSA 為同策略（On-policy）方法，其更新基於下一步實際採取的行動。這表示 SARSA 會將探索策略所帶來的隨機性與風險納入考量。因此，SARSA 學習到的策略會避開高危險區域，傾向安全路徑。

一般而言，Q-learning 傾向學習理論最優策略，但訓練過程具高風險；SARSA 傾向在實際探索策略下學習較安全、穩定的行為。

(三) 結論

• 收斂較快的方法：若以策略達到最優狀態的速度為準，Q-learning 較快；若以累積獎勵趨於穩定的速度為準，SARSA 較快。

• 較穩定的方法：SARSA 在訓練過程中展現較高的穩定性與較小的獎勵波動。

• 選擇情境：

- Q-learning：適用於環境允許試錯、懲罰成本可承受，或最終部署時能完全關閉探索以執行純粹最優策略的情境。

- SARSA：適用於探索過程中的錯誤成本極高（如自動駕駛、醫療決策），或系統必須在持續探索的情況下安全運行的情境。